

Rilevamento di cyber-recon e scanning avanzato in reti critiche

Antonio Sirignano^{*,a,1}

^aUNINA

This manuscript was compile on September 12, 2026

Abstract

Elaborato progettuale per l'esame di Cognitive Computing Systems.

1. INTRODUZIONE

Le attività di ricognizione di rete (*cyber-reconnaissance* e *port scanning*) costituiscono la prima fase critica della catena di attacco (*Cyber Kill Chain*).

In tale fase, un attaccante si dedica all'individuazione di nuovi sistemi, mappare reti e cercare particolari vulnerabilità, le quali possono essere sfruttate.

La maggior parte dei **Sistemi di Rilevamento delle Intrusioni** — (IDS) basati su machine learning analizza il traffico concentrandosi sui singoli flussi di rete presi in modo atomico e isolato (*approccio flow-based*), ignorando il contesto sequenziale e temporale che lega connessioni successive.

L'analisi isolata dei flussi mostra severe limitazioni operative in ambienti reali caratterizzati da un notevole sbilanciamento delle classi. Sebbene le metriche ROC-AUC possano restituire valori illusoriamente prossimi all'unità, l'assenza di contesto temporale genera un'elevata frequenza di falsi positivi nei range intermedi di probabilità, depredando l'Area sotto la curva Precision-Recall (PR-AUC).

Tale lavoro presenta l'architettura e la valutazione empirica di **Early Cyber-Recon Detector**, pipeline modulare ad alte prestazioni progettata per il rilevamento precoce di attacchi di ricognizione sul dataset CIC-IDS2017. Per superare le rigidità dei modelli convenzionali, la soluzione implementa una **finestra scorrevole continua retrograda** (*backward rolling window*) tramite l'engine ad alta velocità **Polars**.

2. DATASET E PREPROCESSING

2.1. Panoramica del Dataset: CIC-IDS2017

La validazione sperimentale si basa sul dataset **CIC-IDS2017**, uno degli standard di riferimento per la valutazione dei *Networks IDS*.

Sebbene il modulo di Ingestion ([downloader.py](#)) integri il supporto automatico per il recupero del dataset **UNSW-NB15** per una futura estensione multi-dataset, l'intera pipeline di preprocessing, estrazione delle features sequenziali e addestramento attivo si incentra su CIC-IDS2017.

Il dataset in questione sintetizza cinque giorni di traffico di rete (da lunedì a venerdì), catturando sia il normale comportamento degli utenti sia otto differenti vettori d'attacco. Le metriche di flusso originali, estratte tramite il software *CICFlowMeter*, forniscono un insieme di oltre 80 features statistiche bidirezionali che descrivono parametri quali la durata, la dimensione dei pacchetti e gli intervalli di inter-arrivo.

2.2. Filtraggio e Isolamento classe Target

L'obiettivo del sistema è l'identificazione delle sonde di ricognizione (*PortScans* e *Reconnaissance*). Nei dataset di intrusion detection, la presenza di vettori d'attacco eterogenei (come Dos, DDoS, Web Attacks e Infiltration) pone un problema metodologico: considerare tali attacchi come parte del traffico lecito **BENIGN** introdurrebbe un grave inquinamento dei dati, distorcendo il profilo di traffico pulito.

Per garantire una perfezione quantomeno concettuale al dataset, la pipeline applica una regola di filtraggio rigorosa:

- **Classe negativa** ($y = 0$): flussi identificati esclusivamente come **BENIGN**
- **Classe positiva** ($y = 1$): flussi etichettati esplicitamente come **PortScan** o riconducibili ad attività di scansione
- **Esclusione selettiva**: tutti i flussi appartenenti ad altre categorie di attacco vengono scartati a livello di ETL prima della fase di vettorizzazione. In questo modo la superficie decisionale del modello impara a separare unicamente il traffico lecito dal restante.




Figure 1. Class Distribution CIC-IDS2017

2.3. Gestione dello Sbilanciamento e Protocollo di Splitting

Il dataset finale filtrato rispecchia la marcata asimmetria tipica di contesti reali di monitoraggio aziendale:

- **Dimensione Complessiva**: 2.432.027 flussi puliti
- **Distribuzione delle Classi**: la classe minoritaria **RECON** costituisce circa il 6, 5% del dataset totale.
- **Partizionamento stratificato (80/20)**: la suddivisione tra Train Set e Test Set viene effettuata tramite uno split stratificato. Ciò assicura che sia la matrice di addestramento che la matrice di valutazione conservino esattamente la medesima proporzione di classe positiva, creando il presupposto per il calcolo dinamico del peso `scale_pos_weight` in LightGBM.

*Corresponding author: ant.sirignano@studenti.unina.it (A. One).

[†]These authors contributed equally to this work.

This document class was prepared on Overleaf and compiled with pdfTeX. No errors were found during the compilation process. Rho-class supports external editors, though additional setup may be required.




Figure 2. CIC-IDS2017 - Flow Duration $[\log_{10}(x + 1)]$ e Fwd Total Packets (Log Scale)

3. INGEGNERIZZAZIONE DELLE FEATURE SEQUENZIALI CON FINESTRA SCORREVOLE CONTINUA

3.1. Limiti dei blocchi discreti

Si supponga ci voler valutare la correlazione temporale tra flussi consecutivi mediante una divisione a blocchi fissi e disgiunti. Tale approccio a blocchi discreti mostra però una criticità concettuale: assegnare valori aggregati identici a tutte le N righe appartenenti allo stesso blocco genera una “funzione gradin” nei dati. Di conseguenza, il classificatore produce probabilità quantizzate a scatti, deprimendo la calibrazione delle stime e degradando la curva Precision-Recall. I blocchi fissi falliscono nel tracciare l'evoluzione graduale di una scansione e introducono una dipendenza arbitraria dai confini del blocco stesso.

3.2. True Rolling Window

Per eliminare gli artefatti della discretizzazione e ripristinare la continuità del segnale, si adotta una **finestra scorrevole retrograda** (*backward rolling window*). Inizializzando un indice intero progressivo (`_row_idx`), le aggregazioni vengono ricalcolate in maniera dinamica per ogni flusso i , considerando la cronologia degli N flussi immediatamente precedenti:

$$W_i = \{f_j \mid \max(0, i - N) \leq j \leq i\} \quad (1)$$

Il valore calcolato per l'evento i non impiega alcuna informazione sui flussi futuri, preservando la casualità temporale indispensabile per un impiego in tempo reale.

3.3. Spazio delle Feature Correlate

L'applicazione della finestra mobile introduce 3 nuove variabili sequenziali ad alto valore informativo, portandoci lo spazio delle feature complessivo da 24 a 27:

- `corr_unique_dst_ports_w50`: conteggio del numero di porte di destinazione uniche contattate negli ultimi 50 flussi ($N = 50$)
- `corr_avg_fwd_pkt_std_w50`: media della deviazione standard della dimensione dei pacchetti forward nella finestra.
- `corr_avg_duration_w50`: durata media delle connessioni nella finestra, ideale per identificare raffiche di tentativi di connessione.

4. MODELLO DI CLASSIFICAZIONE E STRATEGIA DI ADDESTRAMENTO

4.1. LightGBM

Per la fase di classificazione è stato selezionato **LightGBM** (*Light Gradient Boosting Machine*), un algoritmo basato su alberi di decisione con accrescimento *leaf-wise* (ovvero guidato dalle foglie con maggior perdita) e discretizzazione in istogrammi (*Histogram-based Gradient Boosting*).

La scelta di LightGBM è giustificata dalle seguenti caratteristiche del modello:

- **Efficienze Computazionale su Dati Massivi:** con quasi 2.5 milioni di flussi di rete analizzati nel dataset, la costruzione degli alberi basata sugli istogrammi riduce drasticamente la memoria necessaria e accelera l'addestramento senza intaccare la precisione.
- **Capacità di Gestione di Dati Tabulari Asimmetrici:** le metriche di traffico di rete presentano distribuzioni fortemente asimmetriche e feature a variazione continua. Gli alberi di decisione gradient-boost sono intrinsecamente immuni alle distorsioni da linearità e non richiedono assunzioni sulla distribuzione gaussiana dei dati.
- **Velocità di Inferenza:** in un contesto come tale progetto, la latenza di predizione per singolo flusso deve essere nell'ordine dei microsecondi per consentire l'intervento prima delle fasi successive dell'attacco.

4.2. Gestione dello Sbilanciamento delle Classi

Nel set di addestramento, la classe minoritaria di attacco `RECON` conta il 6,5% dei campioni, fronte dei campioni `BENIGN`, 93,4%. Un classificatore standard privo di bilanciamento tenderebbe ad appiattirsi sulla classe maggioritaria per massimizzare l'accuracy complessiva, penalizzando il tasso di rilevamento degli attacchi.

Per contrastare tale fenomeno senza ricorrere a tecniche di oversampling sintetico, il parametro `scale_pos_weight` viene calcolato in modo dinamico sulla matrice di train:

$$\text{scale_pos_weight} = \frac{N_{\text{BENIGN}}}{N_{\text{RECON}}} \quad (2)$$

Tale valore agisce direttamente sulla funzione di perdita, moltiplicandosi il peso dei gradienti associati ad errori di classificazione su campioni di attacco `RECON`. In questo modo, l'algoritmo penalizza severamente i falsi negativi.

4.3. Isolamento dello scaling e prevenzione di data leakage

Per garantire la validità scientifica delle metriche ed evitare qualsiasi forma di data leakage tra Train e Test Set:

- **Trasformazione Logaritmica:** alle variazioni ad elevata asimmetria viene applicata la funzione $y = \log_{10}(x + 1)$ per contenere gli outlier estremi.
- **RobustScaler Isolato:** normalizzazione basata sulla mediana e sull'Interquartile Range (IQR) viene calcolata eseguendo il `fit_transform` esclusivamente sul set di addestramento. Le statistiche estratte dal train ($\bar{x}_{\text{train}}$, $\text{IQR}_{\text{train}}$) vengono estratte in modalità read-only sul Test Set, garantendo che nessuna informazione sulla popolazione di test sia visibile al modello.

4.4. Architettura di Caching Doppia e Riproducibilità

Per condurre un'analisi comparativa rigorosa, la pipeline implementa una gestione della persistenza separata. L'esecuzione delle due configurazioni produce e memorizza artefatti distinti. Questo isolamento fisico consente al notebook di valutazione di caricare entrambi i modelli ed entrambe le metriche di test contemporaneamente, eliminando il rischio di sovrascrittura accidentale della cache.

5. VALUTAZIONE SPERIMENTALE E ANALISI DEI RISULTATI

5.1. Metriche di Valutazione per Dataset Sbilanciati

Nei sistemi di intrusion detection caratterizzati da una sproporzione delle classi, le metriche convenzionali come l'Accuracy o la ROC-AUC possono risultare ingannevoli.

Nello specifico, la curva ROC pone in relazione il *True Positive Rate* con il *False Positive Rate*. Poiché il denominatore di FPR è rappresentato dall'elevato numero assoluto di campioni negativi, anche centinaia di falsi allarmi producono una variazione insignificante su FPR. Di conseguenza, entrambi i modelli

registrano valori di ROC-AUC prossimi alla perfezione. Per valutare la reale efficacia operativa del sistema si adotta l'**Area sotto la Curva Precision-Recall**, definita come

$$\text{PR-AUC} = \int_0^1 P(R)dR \quad (3)$$

La Precision impiega al denominatore unicamente i positivi predetti. Questo rende il PR-AUC estremamente sensibile alla presenza di falsi positivi nei range di probabilità intermedi, ponendolo come metrica primaria per validare l'abbattimento di falsi allarmi.

5.2. Confronto Prestazionale

La valutazione è stata condotta sulla matrice di Test.

Table 1. Performance Comparison: Base vs. Correlated Rolling Model

Modello	PR-AUC	ROC-AUC	Precision (RECON)	Recall (RECON)
Base (24 Feature)	0.7498	0.9999	0.99	1.00
Correlato Rolling (27 Feature)	0.9502	1.0000	1.00	1.00
Incremento (Δ)	+0.2004	+0.0001	+0.01	0.00

Note: Metrics evaluated on the CIC-IDS2017 test set comprising 486,406 total flows.

5.3. Analisi Comparazione

Si hanno 4 grafici indipendenti per effettuare un'analisi visiva delle curve:




Figure 3

Pannelli superiori (modello base) evidenziano come la curvta Precision-Recall pur mantenendo una Recall del 100% mostri un flessio marcato dove la Precision decade prima di stabilizzarsi, fissando PR-AUC a 0,7498.

I pannelli ingeriori (modello correlato), mostrano la curva Precision-Recall che si mantiene ancorata all'angolo superiore destro. Viene inoltre inserita una linea di riferimento teorica che evidenzia il guadagno informativo netto garantito dall'infrastruttura rispetto ad una scelta casuale.

5.4. Decodifica della Feature Importance: Gain vs Split

L'interpretazione dei nodi decisionali all'interno del modello ha rilevato un'importante distizione metodologica tra il conteggio degli Split

e il calcolo del Gain.

- **Analisi basata sugli Split:** misura quante volte una variabile viene scelta per suddividere un nodo.
- **Analisi basata su Gain** misura la riduzione complessiva dell'entropia portata da ciascuna feature

Table 2. Feature Importance Analysis Ranked by Information Gain

Rank	Category	Feature Name	Total Gain	Splits
1	[BASE]	Packet Length Mean	20 533 472.70	190
2	[CORR]	corr_avg_fwd_pkt_std_w50	11 616 661.49	439
3	[BASE]	Bwd Packet Length Mean	4 071 736.04	116
4	[BASE]	Fwd IAT Mean	1 734 072.83	131
14	[CORR]	corr_avg_duration_w50	48 510.81	318

Note: Information Gain reflects the total entropy reduction brought by each feature across all LightGBM trees.

I risultati confermano che la variabile sequenziale `corr_avg_fwd_pkt_std_w50` è la seconda feature più importante all'interno del modello per impatto informativo.

Questo dato fornisce la spiegazione matematica del successo del modello: la deviazione standard media della dimensione dei pacchetti calcolata sulla finestra mobile offre un potere discriminante immediato, consentendo agli alberi di eliminare la quasi totalità dell'incertezza con pochissime decisioni ad altissima precisione.

REFERENCES

- [1] H.-J. Liao, C.-H. Richard Lin, Y.-C. Lin, and K.-Y. Tung, "Intrusion detection system: A comprehensive review," *Journal of Network and Computer Applications*, vol. 36, no. 1, pp. 16–24, 2013, ISSN: 1084-8045. DOI: <https://doi.org/10.1016/j.jnca.2012.09.004> [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1084804512001944>
- [2] H. Yang, G. Qin, Z. Liu, Y. Hu, and Q. Dai, *Lightgbm robust optimization algorithm based on topological data analysis*, 2024. arXiv: 2406.13300 [cs.LG]. [Online]. Available: <https://arxiv.org/abs/2406.13300>
- [3] R. Panigrahi, *Cicids2017*, 2025. DOI: 10.21227/akxq-9v09 [Online]. Available: <https://dx.doi.org/10.21227/akxq-9v09>